

Guía de Actividades Práctico- Experimentales Nro. 012

Datos Generales

Estudiantes:	Kiara Condoy, Héctor Guerrero, Javier Guarnizo, Ricardo Ochoa, Emily Salas
Asignatura	Teoría de la Distribución y Probabilidad
Ciclo	2do "A"
Unidad	3
Resultado de aprendizaje de la unidad	Comprende los conceptos de variable aleatoria multidimensional y distribución de probabilidad asociada, bajo los principios de solidaridad, transparencia, responsabilidad y honestidad.
Práctica Nro.	012
Título de la Práctica	Análisis Bivariado y Predicción: Correlación de Pearson y Modelo de Regresión Lineal Simple (OLS)
Nombre del Docente	Cristian Ramiro Narváez Guillén
Fecha	Martes 06 de julio del 2026
Horario	11h30 – 13h30
Lugar	EVA Aula
Tiempo planificado en el Sílabo	2 horas

1. Objetivo(s) de la Práctica:

- **Construir** un modelo de Regresión Lineal Simple basado en el método de Mínimos Cuadrados Ordinarios (OLS) aplicado a dos variables críticas del dataset regional del Proyecto Integrador (ABP).
- **Investigar** y validar estadísticamente los supuestos subyacentes del modelo de regresión lineal (normalidad y homocedasticidad de los residuos) para garantizar la confiabilidad geométrica de la recta ajustada (ABI).

- **Cuantificar** la fuerza y dirección de la relación lineal entre dos variables continuas mediante el cálculo del Coeficiente de Correlación de Pearson (r) utilizando scipy.stats.

2. Materiales y reactivos:

- Entorno de desarrollo interactivo (Jupyter Notebook, Google Colab o Anaconda).
- Librerías de Python preinstaladas: numpy, pandas, scipy.stats, matplotlib, seaborn.
- Dataset regional del Proyecto Integrador limpio y validado.
- Conexión a Internet estable y continua.
- Navegador web actualizado.xl

3. Equipos y herramientas

- Recursos físicos: Aula de Computación.
- Computadora personal o portátil (PC o Laptop):
- Sistema operativo: Windows, Linux o macOS.
- Procesador: mínimo 2 núcleos (recomendado 4).
- Memoria RAM: mínimo 4 GB (recomendado 8 GB para manipulación de datasets con pandas).

4. Procedimiento / Metodología

Enfoque PID-2025:

- **ABP (Aprendizaje Basado en Problemas):** El estudiante evolucionará de describir el pasado (estadística descriptiva) a predecir el futuro. Deberá encontrar qué variable de su región explica matemáticamente el comportamiento de otra, y utilizar esta relación para pronosticar escenarios no observados.
- **ABI (Aprendizaje Basado en Investigación):** Indagación crítica sobre por qué "Correlación no implica Causalidad" y la comprobación matemática rigurosa de los errores (residuos). Un modelo con buen R^2 puede ser engañoso si los residuos no son aleatorios.
- **Duración sugerida:** 120 min. (presencial).
- **Modalidad:** Ejecución técnica individual, con interpretación predictiva orientada al Hito del Proyecto en grupos.

Tarea 1: Análisis de Correlación de Pearson

El coeficiente de correlación de Pearson (r) mide la dependencia lineal entre dos variables, oscilando entre -1 (correlación negativa perfecta) y 1 (correlación positiva perfecta).

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}}$$

Abra un nuevo Jupyter Notebook llamado APE_013_Regresion.ipynb.

Escenario: Analizaremos la relación entre los "Usuarios Concurrentes" en un servidor (X) y el "Consumo de Ancho de Banda en Mbps" (Y).

```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from scipy.stats import pearsonr

# Generación de datos simulados (Relación positiva fuerte con ruido)
np.random.seed(42)
usuarios_X = np.random.randint(50, 500, size=100)
# Y = 2.5*X + 50 + Ruido Aleatorio
ancho_banda_Y = 2.5 * usuarios_X + 50 + np.random.normal(0, 100, size=100)

# 1. Cálculo del Coeficiente de Pearson y su valor-p
coef_pearson, p_valor = pearsonr(usuarios_X, ancho_banda_Y)

print("--- Análisis de Correlación de Pearson ---")
print(f"Coeficiente (r): {coef_pearson:.4f}")
print(f"Valor-p (Significancia): {p_valor:.4e}")

if p_valor < 0.05:
    print("Conclusión: Existe una correlación lineal estadísticamente significativa.")
else:
    print("Conclusión: NO existe evidencia de correlación lineal significativa.")
```

2. Visualización: Diagrama de Dispersión (Scatter Plot)

```
plt.figure(figsize=(8, 5))
sns.scatterplot(x=usuarios_X, y=ancho_banda_Y, color='blue', alpha=0.7)
plt.title(f'Dispersión: Usuarios vs Ancho de Banda (r = {coef_pearson:.2f})')
plt.xlabel('Usuarios Concurrentes (X)')
plt.ylabel('Ancho de Banda Mbps (Y)')
plt.grid(True, linestyle='--', alpha=0.5)
plt.show()
```

Tarea 2: Ajuste del Modelo de Regresión Lineal Simple (OLS)

Si existe correlación, podemos modelar la relación mediante una línea recta:

$\hat{y} = \beta_0 + \beta_1 x$, donde β_0 es el intercepto y β_1 la pendiente.

1. Utilizaremos statsmodels, ya que provee un resumen estadístico profundo al estilo de la econometría clásica.
2. Agregue y ejecute el siguiente código en su cuaderno:

```
import statsmodels.api as sm
```

```
# Para usar statsmodels, debemos añadir explícitamente la constante
(intercepto beta_0) al predictor X
```

```
X_sm = sm.add_constant(usuarios_X)
```

```
Y_sm = ancho_banda_Y
```

```
# Ajuste del modelo por Mínimos Cuadrados Ordinarios (OLS)
```

```
modelo_ols = sm.OLS(Y_sm, X_sm).fit()
```

```
# Impresión del resumen estadístico
```

```
print(modelo_ols.summary())
```

```
# Extracción de parámetros para graficar la recta
```

```
beta_0 = modelo_ols.params[0]
```

```
beta_1 = modelo_ols.params[1]
```

```
plt.figure(figsize=(8, 5))
```

```
sns.scatterplot(x=usuarios_X, y=ancho_banda_Y, label='Datos Observados',
```

```
color='gray')
# Dibujo de la recta de regresión
plt.plot(usuarios_X, beta_0 + beta_1 * usuarios_X, color='red', linewidth=2,
label=f'Recta: Y = {beta_0:.2f} + {beta_1:.2f}X')
plt.title('Modelo de Regresión Lineal Simple')
plt.xlabel('Usuarios Concurrentes (X)')
plt.ylabel('Ancho de Banda Mbps (Y)')
plt.legend()
plt.show()
```

Tarea 3: Hito del Proyecto - Predicción en el Dataset Regional (ABP)

1. Importe su dataset regional mediante pandas.
2. Identifique una variable independiente/predictora (X) y una variable dependiente/respuesta (Y). Ejemplo: $X = \text{Precipitación}$, $Y = \text{Producción Agrícola}$.
3. Aplique el flujo de las Tareas 1 y 2: Calcule r , ajuste el modelo OLS e imprima el summary().
4. **Predicción:** Usando los coeficientes obtenidos (β_0, β_1) , calcule manualmente mediante código Python el valor esperado de Y para un valor crítico de X que **no** exista en su dataset original (pronóstico).
5. Interprete desde la perspectiva del negocio el valor del **R-squared (R^2)** que le arrojó el resumen estadístico.

5. Resultados esperados:

Al finalizar esta práctica, el estudiante será capaz de:

- Modelado Teórico y Correlación (2.0 puntos): Ejecución exitosa de las Tareas 1 y 2, mostrando el cálculo correcto del coeficiente de Pearson, el valor-p y la superposición de la recta OLS.
- Aplicación Predictiva Regional (ABP) (3.0 puntos): Selección coherente de las variables X e Y, ajuste del modelo y la interpretación técnica del resumen de *statsmodels* (específicamente R-squared y otros estadísticos).

- Diagnóstico de Residuos (ABI) (2.5 puntos): Aplicación del test de Shapiro-Wilk sobre los residuos (.resid) y generación del gráfico de dispersión "Valores Ajustados vs Residuos", acompañado de un dictamen sobre la validez del modelo.

6. Preguntas de Control:

1. ¿Cuál es el coeficiente de correlación de Pearson (r) entre el Año (X) y la Pérdida de Cobertura Arbórea (Y) en la provincia de Loja y qué indica sobre la relación entre ambas variables?

- **Coeficiente de correlación (r):** -0.1438 (con un valor-p de 0.5026).
- **Interpretación:**
 - **Dirección y Fuerza:** El valor $r = -0.1438$ indica una **correlación negativa sumamente débil** (cercana a cero) entre el paso de los años y la deforestación en la provincia de Loja.
 - **Significancia Estadística:** Dado que el p-valor (0.5026) es considerablemente mayor al nivel de significancia estándar $\alpha = 0.05$, **se concluye que la correlación lineal no es estadísticamente significativa**. Es decir, no existe evidencia estadística para afirmar que la pérdida de cobertura arbórea aumente o disminuya de forma lineal sistemática a medida que avanzan los años.

2. ¿Qué porcentaje de la variabilidad en la pérdida de cobertura arbórea es explicado por el tiempo (Año) según el modelo OLS ajustado?

- **Coeficiente de Determinación (R²):** 0.0207 (2.1%).
- **Interpretación de Negocio:**
 - El tiempo (medido en años) explica **únicamente el 2.1% de la variabilidad total** en la pérdida de hectáreas de bosque en Loja. El 97.9% restante depende de otros factores no incluidos en este modelo simple.
 - Para la toma de decisiones o políticas públicas de conservación, el modelo demuestra que el año por sí solo **no es un predictor confiable**. La deforestación está impulsada por dinámicas multivariadas (presión agrícola, incendios forestales, variabilidad climática, expansión urbana, minería, etc.) que deben ser consideradas en modelos de regresión múltiple.

3. Escriba la ecuación de la recta de regresión ajustada y detalle el valor estimado (Y) de pérdida de cobertura arbórea para el año 2026.

- **Parámetros del modelo ajustado:**
 - Intercepto (β_0): 18515.4167
 - Pendiente (β_1): -8.6622
- **Ecuación de la recta:**

$$Y^{\wedge} = 18515.4167 - 8.6622 \cdot X$$

- **Predicción para el año 2026 (X=2026):**

$$Y^{\wedge} 2026 = 18515.4167 + (-8.6622 \times 2026)$$

$$Y^{\wedge} 2026 = 18515.4167 - 17549.6172 = 965.80 \text{ hectareas}$$

(en el notebook se aproxima a 965.85 ha según el redondeo de los coeficientes).

4. Con base en el diagnóstico de los residuos (Test de Shapiro-Wilk y gráfico de residuos), ¿es válido el modelo de Regresión Lineal Simple para realizar inferencias? Justifique.

- **Resultados del Test de Shapiro-Wilk:**
 - Estadístico $W=0.8831$
 - valor- $p=0.0096$
- **Dictamen sobre la Validez del Modelo:**
 - **El modelo NO es estadísticamente válido para inferencia.**
 - **Justificación:** Dado que el p-valor (0.0096) del test de Shapiro-Wilk es **menor a 0.05**, se rechaza la hipótesis nula de normalidad, concluyendo que **los residuos no siguen una distribución normal**. Al violarse el supuesto de normalidad de los residuos, las inferencias estadísticas derivadas del modelo (intervalos de confianza, pruebas t y pruebas F) pierden validez operativa.

7. Conclusiones.

Diferencia entre simulación teórica y datos reales de series temporales:

La práctica permitió contrastar dos escenarios: en la *Tarea 1*, con datos simulados mediante una relación matemática directa ($Y=2.5X+50+\text{ruido}$), se obtuvo una fuerte correlación lineal ($r=0.9603$, $R^2=0.922$). Por el contrario, en el *dataset* real de Global Forest Watch (Pérdida de cobertura arbórea en Loja), el modelo mostró que la variable temporal aislada carece de poder predictivo ($r=-0.1438$, $R^2=0.0207$), evidenciando que los fenómenos ambientales reales rara vez se ajustan a modelos lineales simples basados únicamente en el tiempo.

Importancia crítica de la validación de supuestos estadísticos:

El ajuste de un modelo de mínimos cuadrados ordinarios (OLS) no concluye con la obtención de los parámetros β_0 y β_1 ni con el cálculo de la ecuación de la recta. El diagnóstico posterior de los residuos mediante la prueba de Shapiro-Wilk ($W=0.8831, p=0.0096$) demostró la violación del supuesto de normalidad, lo que invalida el uso del modelo OLS para realizar pruebas de hipótesis o proyecciones formales sin una transformación previa de variables o la aplicación de modelos econométricos no paramétricos/multivariados.

Relevancia del análisis estadístico enfocado a la toma de decisiones en el territorio:

Desde la perspectiva de la gestión pública e inversión en la provincia de Loja, el análisis cuantitativo evita la adopción de predicciones simplistas e erróneas. Al determinar que el año explica apenas el 2.1% de la deforestación, se concluye que las intervenciones y políticas de conservación ambiental deben respaldarse en modelos analíticos complejos que incorporen covariables explicativas de peso, tales como el uso del suelo, factores socioeconómicos, variables meteorológicas y normativas locales.



unl

Universidad
Nacional
de Loja

FEIRNNR - Carrera de
Computación

Enlace del Google Colab:

<https://colab.research.google.com/drive/1ajUVmqKOj8Q3mblzmAN0RBGBJhNEz91O?usp=sharing>

Chat con el uso de IA:

<https://share.gemini.google/aH9zFmSggg8b>

8. Bibliografía

- [1] R. E. Walpole, R. H. Myers, S. L. Myers, y K. Ye, *Probabilidad y estadística para ingeniería y ciencias*, 9na ed. Pearson Educación, 2012.
- [2] W. McKinney, *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*, 3ra ed. O'Reilly Media, 2022.
- [3] SciPy Developers, "scipy.stats Documentation," *SciPy.org*, 2024. [Online]. Disponible: <https://docs.scipy.org/doc/scipy/reference/stats.html>.