

Guía de Actividades Práctico-Experimentales Nro. 013

Datos Generales

Asignatura	Teoría de la Distribución y Probabilidad
Ciclo	2do "A"
Nombres	Kiara Condoy, Héctor Guerrero, Javier Guarnizo, Ricardo Ochoa, Emily Salas.
Resultado de aprendizaje de la unidad	Comprende los conceptos de variable aleatoria multidimensional y distribución de probabilidad asociada, bajo los principios de solidaridad, transparencia, responsabilidad y honestidad.
Práctica Nro.	013
Título de la Práctica	Análisis Predictivo Multivariado: Regresión Lineal Múltiple y Diagnóstico de Multicolinealidad (VIF)
Nombre del Docente	Cristian Ramiro Narváez Guillén
Fecha	Martes 13 de julio del 2026
Horario	11h30 - 13h30
Lugar	EVA Aula
Tiempo planificado en el Sílabo	2 horas

1. Objetivo(s) de la Práctica:

- Construir un modelo de Regresión Lineal Múltiple integrando varios predictores continuos mediante el método de Mínimos Cuadrados Ordinarios (OLS) en statsmodels.
- Aplicar el modelado multivariado al conjunto de datos regional del Proyecto Integrador, seleccionando las variables predictoras más significativas basándose en el R^2 Ajustado y los valores- p parciales (ABP).



unl

Universidad
Nacional
de Loja

FEIRNNR - Carrera de Computación

- Investigar y ejecutar pruebas de diagnóstico avanzado, específicamente el Factor de Inflación de la Varianza (VIF), para identificar y mitigar la multicolinealidad estructural en los datos (ABI).

2. Materiales y reactivos:

- Entorno de desarrollo interactivo (Jupyter Notebook, Google Colab o Anaconda).
- Librerías de Python preinstaladas: numpy, pandas, scipy.stats, matplotlib, seaborn.
- Dataset regional del Proyecto Integrador limpio y validado.
- Conexión a Internet estable y continua.
- Navegador web actualizado.x|

3. Equipos y herramientas

- Recursos físicos: Aula de Computación.
- Computadora personal o portátil (PC o Laptop):
- Sistema operativo: Windows, Linux o macOS.
- Procesador: mínimo 2 núcleos (recomendado 4).
- Memoria RAM: mínimo 4 GB (recomendado 8 GB para manipulación de datasets con pandas).

4. Procedimiento / Metodología

Enfoque PID-2025:

- ABP (Aprendizaje Basado en Problemas): El estudiante descubrirá que predecir el comportamiento de su región usando una sola variable (Semana 13) es impreciso. Deberá combinar múltiples factores (ej. temperatura, humedad y altitud para predecir rendimiento agrícola) y decidir si vale la pena la complejidad adicional del modelo.
- ABI (Aprendizaje Basado en Investigación): Indagación sobre el "castigo matemático" que aplica el R^2 Ajustado cuando se añaden variables "basura" al modelo, y cómo descubrir si dos predictores están compitiendo entre sí (Multicolinealidad).
- Duración sugerida: 120 min. (presencial).
- Modalidad: Ejecución técnica individual con consolidación del modelo final para el Proyecto Integrador en grupos.

Tarea 1: Ajuste del Modelo de Regresión Lineal Múltiple

La Regresión Lineal Múltiple expande la ecuación a un hiperplano de k dimensiones:

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + \epsilon$$

Abra un nuevo Jupyter Notebook llamado APE_014_RegresionMultiple.ipynb.

Escenario: Predecir el **Tiempo de Compilación de un Software en segundos** (Y) basándonos en las **Líneas de Código** (X_1) y la **Memoria RAM disponible en GB** (X_2).

```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
import statsmodels.api as sm
```

1. Generación de datos simulados multivariados

```
np.random.seed(42)
n_muestras = 150
```

```
lineas_codigo = np.random.randint(5000, 50000, size=n_muestras) # X1
ram_disponible = np.random.uniform(4.0, 32.0, size=n_muestras) # X2
```

```
# Y = B0 + B1*X1 + B2*X2 + Error
# A más líneas, más tiempo (+). A más RAM, menos tiempo (-)
tiempo_compilacion = 15.0 + (0.002 * lineas_codigo) - (1.5 * ram_disponible) +
np.random.normal(0, 15, size=n_muestras)
```

```
df_simulado = pd.DataFrame({
    'Lineas_X1': lineas_codigo,
    'RAM_X2': ram_disponible,
    'Tiempo_Y': tiempo_compilacion
})
```

2. Configuración de la matriz de características X y el vector Y

```
X_multi = df_simulado[['Lineas_X1', 'RAM_X2']]
Y_multi = df_simulado['Tiempo_Y']
```



unl

Universidad
Nacional
de Loja

```
# Añadir la constante (Intercepto B0)
```

```
X_multi_sm = sm.add_constant(X_multi)
```

```
# 3. Ajuste del Modelo OLS Múltiple
```

```
modelo_multiple = sm.OLS(Y_multi, X_multi_sm).fit()
```

```
# Imprimir el resumen estadístico
```

```
print(modelo_multiple.summary())
```

Tarea 2: Hito del Proyecto - Modelado Predictivo Regional (ABP)

1. Importe su dataset regional mediante pandas.
2. Defina su Variable Respuesta (Y) y seleccione **al menos dos** Variables Predictoras ($X_1, X_2, \dots, X_k$).
3. Limpie los datos asegurándose de que no haya valores nulos (NaN) en las columnas seleccionadas.
4. Entrene un modelo OLS Múltiple como en la Tarea 1.
5. **Análisis Crítico:** Redacte un análisis en Markdown interpretando específicamente los coeficientes β_i en el contexto de su problema regional. Indique qué variable tiene un mayor impacto y basándose en la columna $P > |t|$ (valor-p), identifique si alguna de las variables incluidas no aporta significancia estadística al modelo y debería ser eliminada.

Tarea 3: Visualización de Relaciones (Pairplot y Heatmap)

Antes de incluir variables a ciegas, un ingeniero debe inspeccionar las correlaciones cruzadas.

```
# Matriz de Correlación
```

```
matriz_corr = df_simulado.corr()
```

```
# Visualización mediante Heatmap
```

```
plt.figure(figsize=(6, 4))
```

```
sns.heatmap(matriz_corr, annot=True, cmap='coolwarm', fmt=".2f", vmin=-1, vmax=1)
```

```
plt.title('Mapa de Calor: Correlaciones Multivariadas')
```

```
plt.show()
```

```
# Visualización de dispersiones múltiples
```

```
sns.pairplot(df_simulado, kind='reg', plot_kws={'line_kws':{'color':'red'}})
plt.suptitle('Pairplot: Relaciones Bivariadas', y=1.02)
plt.show()
```

Aplique este mismo bloque de código a las variables de su dataset regional (Tarea 2) y documente si observa que dos de sus variables predictoras X están altamente correlacionadas entre sí.

Tarea 4: ABI - Diagnóstico de Multicolinealidad (VIF)

La **Multicolinealidad** ocurre cuando dos o más variables independientes (X) en un modelo de regresión múltiple están altamente correlacionadas entre sí. Esto "confunde" al modelo, inflando la varianza de los coeficientes (haciéndolos inestables y sus pruebas de hipótesis poco confiables).

1. Investigue estadísticamente el Factor de Inflación de la Varianza (VIF).
2. Ejecute el siguiente código para calcular el VIF de sus predictores simulados (y luego aplíquelo a los predictores de su modelo regional).

```
from statsmodels.stats.outliers_influence import variance_inflation_factor
```

```
# Se calcula el VIF para cada variable independiente (incluyendo la constante)
```

```
# VIF = 1 / (1 - Ri2)
```

```
vif_data = pd.DataFrame()
```

```
vif_data["Variable"] = X_multi_sm.columns
```

```
vif_data["VIF"] = [variance_inflation_factor(X_multi_sm.values, i)
```

```
for i in range(X_multi_sm.shape[1])]

```

```
print("\n--- Análisis de Multicolinealidad ---")
```

```
print(vif_data)
```

5. Resultados esperados:

Al finalizar esta práctica, el estudiante será capaz de:

- Construir e interpretar modelos de regresión lineal múltiple con múltiples predictores utilizando herramientas de Python.
- Diagnosticar y mitigar problemas de multicolinealidad estructural mediante el uso del Factor de Inflación de la Varianza (VIF).

- Evaluar la calidad de un modelo predictivo, distinguiendo entre la significancia estadística y la relevancia práctica de las variables independientes.
- Integrar técnicas de análisis multivariado en la resolución de problemas regionales, demostrando pensamiento crítico sobre la utilidad y las limitaciones de los modelos estadísticos.

6. Preguntas de Control:

- **Considerando la naturaleza de la causalidad, ¿cómo la lógica de 'mantener las demás variables constantes' permite aislar el efecto de un factor específico en un fenómeno complejo, y qué limitaciones filosóficas impone esto a la realidad?**

Mecanismo analítico:

Matemáticamente, la regresión lineal múltiple utiliza el supuesto *ceteris paribus* (mantener las demás variables constantes) mediante la estimación de coeficientes parciales β_j . Cada coeficiente representa el cambio esperado en la variable dependiente Y por cada unidad de cambio en X_j , habiendo "descontado" o ajustado linealmente la influencia y la correlación del resto de las variables predictoras incluidas en el modelo.

Limitaciones filosóficas:

- Ilusión del reduccionismo: En la realidad y en la física de los sistemas complejos, los factores no operan de manera aislada. Forzar la condición de mantenerlos constantes presupone un desacoplamiento artificial que muchas veces es físicamente imposible.
- Omitir la no linealidad e interacciones: El supuesto asume que el efecto de una variable es independiente de los niveles en los que se encuentren las demás, ignorando efectos sinérgicos o de interacción no lineal.
- Sesgo de variables omitidas: La validez de este aislamiento depende de haber medido e incluido todas las variables confusoras relevantes. Si falta una variable crítica, el efecto aislado estará contaminado.
- **Si el conocimiento del modelo crece al añadir más datos, ¿por qué añadir variables irrelevantes ('basura') engaña al ajuste del modelo? ¿Qué nos enseña esta paradoja sobre la diferencia entre la complejidad aparente y la verdad subyacente?**

El engaño del ajuste (R^2):

Por definición matemática del método de Mínimos Cuadrados Ordinarios (OLS), el coeficiente de determinación (R^2) es una función monótona no decreciente con respecto al número de regresores. Agregar cualquier variable —incluso si es ruido blanco aleatorio— aprovecha las fluctuaciones muestrales

aleatorias para reducir marginalmente la suma de cuadrados de los residuos, incrementando artificialmente el R^2 .

Complejidad aparente vs. Verdad subyacente:

- Sobreajuste (Overfitting): Aumentar variables irrelevantes hace que el modelo memorice el ruido del conjunto de datos de entrenamiento en lugar de capturar la estructura subyacente real del fenómeno, destruyendo su capacidad de generalización frente a nuevos datos.
- Principio de parsimonia (Navaja de Ockham): La paradoja nos enseña que un modelo más complejo no es un modelo más verídico. La veracidad de un modelo reside en su capacidad para explicar la máxima cantidad de varianza con la menor cantidad de supuestos e información innecesaria, razón por la cual se emplean métricas penalizadas como el R^2 ajustado, AIC o BIC.
- **Ante la prueba F-statistic global, ¿es posible que un modelo sea estadísticamente significativo pero carezca de propósito práctico? ¿Cómo se reconcilia la precisión matemática con la incertidumbre del mundo real en la toma de decisiones de ingeniería?**

Sí, es totalmente posible. La prueba F global evalúa la hipótesis nula de que todos los coeficientes del modelo son simultáneamente iguales a cero ($\beta_1 = \beta_2 = \dots = \beta_k = 0$). Con un tamaño de muestra suficientemente grande ($n \rightarrow \infty$), pequeñas variaciones o correlaciones insignificantes pueden resultar estadísticamente significativas ($p < 0.05$), produciendo un valor de F elevado, aun cuando el modelo explique una fracción ínfima de la varianza total (R^2 muy bajo) o las predicciones tengan un margen de error demasiado alto para ser aplicables.

Reconciliación en la toma de decisiones:

- Análisis de magnitud de efecto y costos: En ingeniería, no basta con saber si un efecto existe (p-valor); se debe evaluar el tamaño del efecto (magnitud del coeficiente) y las tolerancias de diseño o costo-beneficio del sistema.
- Intervalos de predicción y riesgo: La incertidumbre del mundo real se gestiona incorporando intervalos de predicción (que consideran la variabilidad intrínseca del sistema) en lugar de depender únicamente de estimaciones puntuales, aplicando factores de seguridad probabilísticos en el diseño.

- **Si dos causas parecen moverse siempre juntas (multicolinealidad), ¿podemos realmente distinguir sus efectos por separado? ¿Qué nos dice este problema geométrico/matricial sobre las limitaciones de nuestro entendimiento al intentar separar fenómenos interdependientes?**

Imposibilidad de aislamiento:

No, no es posible distinguirlos con precisión. Cuando dos o más variables están fuertemente correlacionadas, no existe suficiente información independiente en la muestra para atribuir los cambios en la variable respuesta a un factor específico.

Fundamento geométrico y matricial:

- Casi-singularidad: En el cálculo de los coeficientes $\beta = (X^T X)^{-1} X^T Y$, la presencia de colinealidad hace que la matriz $X^T X$ sea cuasi-singular (su determinante tiende a cero).
- Inestabilidad de la inversa: La inversión de una matriz casi singular resulta en varianzas y errores estándar de los coeficientes extremadamente altos (disparo del Factor de Inflación de la Varianza - VIF). Geométricamente, el hiperplano de regresión pierde estabilidad y pequeñas fluctuaciones en los datos producen cambios drásticos en los coeficientes.

Lección sobre fenómenos interdependientes:

Esto demuestra que cuando dos fenómenos ocurren siempre acoplados en la naturaleza u observación, intentar forzar una atribución individual causa-efecto mediante modelos puramente observacionales es un problema matemáticamente mal planteado (ill-posed). Para separar sus efectos se requiere experimentación activa (diseño de experimentos) o la reformulación del problema (por ejemplo, mediante Análisis de Componentes Principales - PCA).

- **Ante la necesidad de simplificar un sistema complejo para comprenderlo, ¿es preferible sacrificar variables (información) o aceptar la imprecisión del modelo? ¿Qué define, bajo su criterio, a un 'buen' modelo para la ingeniería?**

Ningún extremo es deseable de forma absoluta; la elección depende del objetivo del análisis:

- Sacrificar variables (Reducción): Introduce un leve sesgo, pero reduce la varianza de la estimación, previene el sobreajuste y aumenta la interpretabilidad. Es la vía preferida cuando se busca control, explicabilidad y toma de decisiones operativas.
- Conservar variables (Complejidad): Retiene información y reduce el sesgo teórico, pero aumenta la varianza, dificulta la interpretación y expone el modelo a la multicolinealidad.

Criterio de un "buen" modelo para la ingeniería:

Un "buen" modelo en ingeniería se rige por el principio expresado por George Box: "Todos los modelos son incorrectos, pero algunos son útiles". Específicamente, debe cumplir con:

- Parsimonia: Explicar la mayor cantidad de variabilidad con la menor complejidad posible.
- Capacidad de generalización: Presentar un bajo error de predicción en datos no vistos previamente (validación cruzada).
- Robustez e interpretabilidad: Proporcionar coeficientes estables y físicamente coherentes que permitan realizar intervenciones o tomar decisiones con un margen de riesgo e incertidumbre cuantificado y aceptable.

7. Conclusiones.

1. La modelación es una simplificación necesaria, no un reflejo perfecto de la realidad

Aislamos variables (*ceteris paribus*) para entender la causalidad, pero en el mundo real los fenómenos están interconectados y raramente operan en el vacío. Reconocer las limitaciones de nuestras premisas y problemas como la multicolinealidad nos recuerda que los modelos matemáticos son aproximaciones útiles, no verdades absolutas.

2. La validez matemática no equivale a verdad ni a utilidad práctica
Añadir más datos o variables irrelevantes puede hacer que un modelo "se vea bien" estadísticamente o apruebe pruebas como la prueba F, pero esto suele ser un espejismo (*overfitting* o ruido). La significancia estadística debe estar siempre respaldada por un tamaño de efecto relevante y un propósito práctico tangible.

3. El "buen" modelo en ingeniería busca el equilibrio entre simplicidad y capacidad de decisión

El objetivo final de la ingeniería no es construir el modelo más complejo ni el más preciso, sino aquel que ofrezca la mejor relación entre simplicidad, interpretabilidad y precisión. Un buen modelo reduce la incertidumbre lo suficiente como para tomar decisiones seguras,



eficientes y confiables con los recursos disponibles.

8. Rúbrica de Evaluación

Esta es la rúbrica simplificada, lista para ser cargada en Moodle:

Criterio	Puntaje	Descripción
Implementación Técnica	3.0 pts	Ejecución correcta del modelo (simulado y



unl

Universidad
Nacional
de Loja

1859

		regional) y limpieza/documentación del código.
Análisis y Diagnóstico	5.0 pts	Interpretación de coeficientes, diagnóstico efectivo de multicolinealidad (VIF) y visualización.
Reflexión Crítica	2.0 pts	Calidad y profundidad en las respuestas a las preguntas de control (enfoque aristotélico).
Total	10.0 pts	

9. Bibliografía

Liste las fuentes utilizadas. Use normas **IEEE**. Pueden ser libros, manuales, artículos, tutoriales académicos, documentación oficial de software.

[1] R. E. Walpole, R. H. Myers, S. L. Myers, y K. Ye, *Probabilidad y estadística para ingeniería y ciencias*, 9na ed. Pearson Educación, 2012.

[2] W. McKinney, *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*, 3ra ed. O'Reilly Media, 2022.

[3] SciPy Developers, "scipy.stats Documentation," *SciPy.org*, 2024. [Online]. Disponible: <https://docs.scipy.org/doc/scipy/reference/stats.html>. [Accedido: 18-Mar-2026].



10. Elaboración y Aprobación

- Elaborado por: nombre del Docente responsable de la práctica.
- Aprobado por: nombre del Director de Carrera.

Elaborado por	Cristian R. Narváez Guillén Docente	
Aprobado por	Edison L Coronel Romero Director de Carrera	