



Guía de Actividades Práctico-Experimentales Nro. 014

Datos Generales

Asignatura	Teoría de la Distribución y Probabilidad
Ciclo	2do "A"
Unidad	3
Resultado de aprendizaje de la unidad	Comprende los conceptos de variable aleatoria multidimensional y distribución de probabilidad asociada, bajo los principios de solidaridad, transparencia, responsabilidad y honestidad.
Práctica Nro.	014
Título de la Práctica	Modelado Probabilístico Avanzado: Regresión Logística, Clasificación Binaria y Matriz de Confusión
Nombre del Docente	Cristian Ramiro Narváez Guillén
Fecha	Martes 20 de julio del 2026
Horario	11h30 – 13h30
Lugar	EVA Aula
Tiempo planificado en el Sílabo	2 horas

1. Objetivo(s) de la Práctica:

- - a. Construir modelos probabilísticos para variables de respuesta binaria utilizando la Función Sigmoide y la Estimación de Máxima Verosimilitud (MLE) a través de statsmodels y scikit-learn.
 - a. Aplicar el modelo de regresión logística al conjunto de datos regional del Proyecto Integrador para predecir la probabilidad de que ocurra un evento de interés, evaluando su precisión empírica (ABP).
 - b. Investigar y demostrar computacionalmente el efecto de modificar el umbral de decisión probabilística (cutoff) sobre las tasas de Error Tipo I y Tipo II mediante el análisis de la Matriz de Confusión (ABI).



2. Materiales y reactivos:

- a. Entorno de desarrollo interactivo (Jupyter Notebook, Google Colab o Anaconda).
- a. Librerías de Python preinstaladas: numpy, pandas, scipy.stats, matplotlib, seaborn.
- b. Dataset regional del Proyecto Integrador limpio y validado.
- c. Conexión a Internet estable y continua.
- d. Navegador web actualizado.x]

3. Equipos y herramientas

- a. Recursos físicos: Aula de Computación.
- a. Computadora personal o portátil (PC o Laptop):
- b. Sistema operativo: Windows, Linux o macOS.
- c. Procesador: mínimo 2 núcleos (recomendado 4).
- d. Memoria RAM: mínimo 4 GB (recomendado 8 GB para manipulación de datasets con pandas).

4. Procedimiento / Metodología

Enfoque PID-2025:

- a. ABP (Aprendizaje Basado en Problemas): El estudiante descubrirá que predecir el comportamiento de su región usando una sola variable (Semana 13) es impreciso. Deberá combinar múltiples factores (ej. temperatura, humedad y altitud para predecir rendimiento agrícola) y decidir si vale la pena la complejidad adicional del modelo.
- a. ABI (Aprendizaje Basado en Investigación): Indagación sobre el "castigo matemático" que aplica el R^2 Ajustado cuando se añaden variables "basura" al modelo, y cómo descubrir si dos predictores están compitiendo entre sí (Multicolinealidad).
- b. Duración sugerida: 120 min. (presencial).
- c. Modalidad: Ejecución técnica individual con consolidación del modelo final para el Proyecto Integrador en grupos.

Enfoque PID-2025:

- d. **ABP (Aprendizaje Basado en Problemas):** El estudiante ya no predice un valor continuo (ej. "cuánto lloverá"), sino la probabilidad de ocurrencia de una condición crítica (ej. "¿Habrá inundación? 1=Sí, 0=No"). Deberá transformar un problema de su región en una pregunta de clasificación binaria.

- **ABI (Aprendizaje Basado en Investigación):** Indagación matemática sobre por qué OLS (Mínimos Cuadrados Ordinarios) falla estrepitosamente al predecir categorías, obligando a la introducción de la función Sigmoide y el pseudo- R^2 .
- e. **Duración sugerida:** 120 min. (presencial).
- f. **Modalidad:** Ejecución técnica individual, con interpretación y ajuste de umbrales en los grupos del Proyecto Integrador.

Tarea 1: Fundamentos de la Regresión Logística (Función Sigmoide)

A diferencia de la regresión lineal, la regresión logística estima la probabilidad $P(Y = 1|X)$. Para garantizar que el resultado esté estrictamente acotado entre $[0, 1]$, se utiliza la función logística (Sigmoide):

1.

$$P(Y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \dots + \beta_k X_k)}}$$

Abra un nuevo Jupyter Notebook llamado APE_015_Logistica.ipynb.

2. Escenario: Predecir la Caída de un Servidor (1 = Sí, 0 = No) basándonos en la Temperatura de la CPU en °C (X_1).

```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
import statsmodels.api as sm
```

```
# 1. Generación de datos simulados (Clasificación Binaria)
```

```
np.random.seed(42)
n_muestras = 200
```

```
# Variable predictora: Temperatura CPU (entre 40 y 90 grados) temp_cpu =
np.random.uniform(40, 90, size=n_muestras)
```

```
# Generar variable binaria probabilística (A mayor temperatura, mayor
probabilidad de falla)
```



```
z = -10 + 0.15 * temp_cpu # Ecuación lineal (Log-Odds)
probabilidad_falla = 1 / (1 + np.exp(-z)) # Transformación Sigmoide

# Variable respuesta binaria (0 = OK, 1 = Falla) basada en la probabilidad
falla_servidor = np.random.binomial(1, p=probabilidad_falla)

df_sim = pd.DataFrame({'Temp_CPU': temp_cpu, 'Falla': falla_servidor})

# 2. Ajuste del Modelo Logístico (Logit)
X_log = sm.add_constant(df_sim['Temp_CPU'])
Y_log = df_sim['Falla']

# Entrenamiento usando MLE (Maximum Likelihood Estimation)
modelo_logit = sm.Logit(Y_log, X_log).fit()

print(modelo_logit.summary())

# 3. Visualización de la Curva Sigmoide
x_rango = np.linspace(30, 100, 300)
x_rango_sm = sm.add_constant(x_rango)
y_pred_prob = modelo_logit.predict(x_rango_sm)

plt.figure(figsize=(8, 5))
sns.scatterplot(x='Temp_CPU', y='Falla', data=df_sim, color='black', alpha=0.5,
label='Datos (0 o 1)')
plt.plot(x_rango, y_pred_prob, color='red', linewidth=2, label='Curva de
Probabilidad Logística')
plt.axhline(0.5, color='gray', linestyle='--', label='Umbral de Decisión (50%)')
plt.title('Regresión Logística: Probabilidad de Falla vs Temperatura')
plt.xlabel('Temperatura CPU (°C)')
plt.ylabel('Probabilidad de Falla P(Y=1)')
plt.legend()
plt.show()
```

Tarea 2: Hito del Proyecto - Predicción Dicotómica Regional (ABP)

1. Importe su dataset regional mediante pandas.
2. Ingeniería de Características: Seleccione una variable continua de interés y binarícela.



- *Ejemplo:* Si tiene "Ingresos", cree una nueva columna Alta_Rentabilidad donde 1 si $\text{Ingresos} > \text{Promedio}$, y 0 si $\text{Ingresos} \leq \text{Promedio}$.
- 3. Seleccione al menos dos variables predictoras (X_1, X_2) para predecir esta nueva variable binaria.
- 4. Ajuste el modelo `sm.Logit()` e imprima el resumen.
- 5. Interprete los resultados: ¿Qué variable(s) incrementa(n) estadísticamente la probabilidad de que ocurra su evento (coeficiente positivo y valor-p < 0.05)?

Tarea 3: Evaluación del Modelo (Matriz de Confusión)

Un modelo de clasificación no se evalúa con el R^2 , sino contando cuántos aciertos y errores cometió.

1. Utilice scikit-learn para calcular las predicciones y generar la Matriz de Confusión del modelo simulado en la Tarea 1.

```
from sklearn.metrics import confusion_matrix, accuracy_score,
ConfusionMatrixDisplay
```

```
# El modelo devuelve probabilidades continuas [0, 1] . Debemos convertirlas a 0 o 1
```

```
# usando un umbral (threshold) estándar de 0.5 (50%)
probabilidades = modelo_logit.predict(X_log)
predicciones_clase = (probabilidades >= 0.5).astype(int)
```

```
# Cálculo de la Matriz de Confusión
```

```
cm = confusion_matrix(Y_log, predicciones_clase)
exactitud = accuracy_score(Y_log, predicciones_clase)
```

```
print(f"\n--- Evaluación del Modelo Probabilístico ---")
print(f"Exactitud Global (Accuracy): {exactitud*100:.2f}%")
```

```
# Visualización
```

```
disp = ConfusionMatrixDisplay(confusion_matrix=cm, display_labels=['OK (0)',
'Falla (1)'] )
disp.plot(cmap='Blues', values_format='d')
```



```
plt.title('Matriz de Confusión (Umbral 0.5)')
```

```
plt.show()
```

¡Apique este mismo proceso para evaluar el modelo de su Proyecto Integrador (Tarea 2).

Tarea 4: ABI - El Análisis del Umbral (Thresholding) y Falsos Positivos

Por defecto, Python asume que si $P(Y = 1) \geq 0.50$, la clasificación es 1. Sin embargo, en ingeniería, el costo de un "Falso Negativo" (predecir que el servidor no fallará y que termine explotando) suele ser mucho mayor que un "Falso Positivo" (ir a revisar un servidor que estaba bien).

1. Investigue cómo alterar el umbral modifica la Matriz de Confusión.
2. Cree un bloque de código que recalculé y muestre la matriz de confusión (o simplemente los valores de Falsos Positivos y Falsos Negativos) utilizando un umbral estricto conservador del 0.20 (es decir, clasificar como 'Falla' si la probabilidad es apenas $\geq 20\%$).
3. Redacte un análisis de qué le sucedió a los Falsos Positivos frente a los Falsos Negativos, y decida qué umbral (0.50 o 0.20) recomendaría para las políticas públicas o de ingeniería en su proyecto regional.

5. Resultados esperados:

Al finalizar esta práctica, el estudiante será capaz de:

- a. Interpretar la relación no lineal entre variables independientes y la probabilidad de un evento dicotómico mediante la función sigmoide.
- a. Justificar la elección de un umbral de decisión (cutoff) basado en el análisis de costos y beneficios (Falsos Positivos vs. Falsos Negativos).
- b. Evaluar críticamente la robustez de un modelo probabilístico utilizando la matriz de confusión.
- c. Traducir coeficientes estadísticos (Log-Odds) en decisiones de ingeniería informadas.

6. Preguntas de Control:

¿Cuál es la esencia matemática de transformar una probabilidad en Log-Odds, y por qué este cambio de dominio es fundamental para el entendimiento de la causalidad probabilística?

La transformación de probabilidad a Log-Odds (función logit) sigue dos pasos:

Odds: Odds = $p/(1-p)$, que lleva el intervalo (0,1) a $[0, +\infty)$.

Logit: $\text{logit}(p) = \ln(p/(1-p))$, que extiende al dominio completo de los reales $(-\infty, +\infty)$.

Esto es crucial porque:



En la escala de Log-Odds, los predictores actúan de manera **aditiva y lineal**, lo que permite interpretar efectos constantes.

Los coeficientes del modelo logístico, al exponenciarse, se convierten en **Odds Ratios**, que cuantifican el impacto causal de un factor sin violar los límites de probabilidad.

¿Por qué la naturaleza del fenómeno (binario) nos obliga a abandonar la medida clásica de bondad de ajuste (R^2) y adoptar el Pseudo R^2 de McFadden, y qué nos dice este cambio sobre la relación entre la realidad y la medición?

En regresión lineal, el R^2 mide proporción de varianza explicada. Pero en fenómenos binarios:

Los residuos no son normales ni tienen varianza constante ($\text{Var}(Y|X)=p(1-p)$).

La noción de “distancia euclidiana” pierde sentido porque los datos son solo 0 o 1.

El **Pseudo R^2 de McFadden** se basa en verosimilitudes:

$$RMcFadden2 = 1 - \ln L_{\text{modelo}} / \ln L_{\text{nulo}}$$

Esto refleja que en lo binario no buscamos minimizar distancias, sino **maximizar la plausibilidad estadística** de los datos observados. La medición se adapta a la naturaleza discreta de la realidad.

Ante un caso de incertidumbre total (predicción 0.5), ¿de qué manera la estructura del modelo intenta forzar una decisión binaria, y qué riesgos enfrentamos al ignorar la zona gris de la probabilidad?

Cuando $p=0.5$, el sistema está en máxima entropía (incertidumbre total). Sin embargo, el modelo suele imponer un **umbral rígido** (por defecto $k=0.5$) para clasificar:

$p \geq 0.5 \rightarrow$ Clase 1

$p < 0.5 \rightarrow$ Clase 0

Riesgos de ignorar la zona gris:

Falsa certeza: casos con $p=0.499$ y $p=0.501$ reciben etiquetas opuestas pese a ser prácticamente iguales.

Fragilidad: pequeñas variaciones de ruido cambian la decisión.

Pérdida de gestión del riesgo: en ámbitos críticos (medicina, finanzas), los casos intermedios deberían derivarse a revisión adicional, no a clasificación automática.

¿Cuál es el conflicto esencial entre la sensibilidad y la especificidad, y cómo la elección de un umbral refleja los valores éticos y técnicos subyacentes en una decisión de ingeniería?

El conflicto surge porque:

Sensibilidad (TPR): detecta positivos, minimiza falsos negativos.

Especificidad (TNR): detecta negativos, minimiza falsos positivos.

Mover el umbral cambia el balance:



unl

Universidad
Nacional
de Loja

Umbral bajo → más sensibilidad, menos especificidad.

Umbral alto → más especificidad, menos sensibilidad.

La elección del umbral refleja valores éticos y técnicos:

Medicina (cáncer): se prioriza sensibilidad (evitar falsos negativos).

Spam: se prioriza especificidad (evitar falsos positivos).

Créditos: se busca balance según apetito de riesgo.

En resumen, el umbral no es solo estadístico, sino una **decisión ética y económica**.

¿Cuál es el propósito final de predecir probabilidades en lugar de estados binarios rígidos, y cómo esta distinción transforma nuestra capacidad de intervenir en la realidad?

El propósito es **preservar la incertidumbre cuantificada**:

Permite **priorizar y ordenar casos** en un ranking continuo (ej. pacientes de mayor riesgo primero).

Desacopla el modelo de las **reglas de negocio**: el modelo da probabilidades, y las decisiones se ajustan según costos o políticas.

Facilita la **calibración del riesgo** mediante valores esperados:

$$\text{Valor Esperado} = p \cdot (\text{Beneficio}) - (1-p) \cdot (\text{Coste})$$

Así, el modelo deja de ser un juez categórico y se convierte en una **herramienta flexible de intervención bajo incertidumbre**, ampliando nuestra capacidad de actuar estratégicamente en la realidad.

7. Conclusiones.

1. Del determinismo a la graduación de la incertidumbre:

Tanto el uso de Log-Odds como la predicción probabilística continua demuestran que los modelos logísticos no buscan clasificar categorías de forma rígida, sino modelar la probabilidad subyacente. Al pasar de un espacio acotado a una escala lineal continua, el modelo conserva la cuantificación de la incertidumbre, evitando tomar decisiones binarias a ciegas y permitiendo priorizar recursos y evaluar riesgos con mayor finura.

2. Criterios de evaluación adaptados a la naturaleza del fenómeno:

La transición del R^2 tradicional al Pseudo R^2 de McFadden responde al cambio fundamental en el objetivo del análisis: en fenómenos binarios no se minimizan distancias de error cuadrático, sino que se maximiza la verosimilitud de los eventos observados. Medir el ajuste en estos modelos exige métricas que entiendan la estructura estocástica del dato y no forzar herramientas concebidas para variables continuas.



3. La toma de decisiones como compromiso técnico y ético:

La elección del umbral de corte (k) y la gestión de la "zona gris" ($p \approx 0.5$) trasladan la estadística al terreno de las decisiones reales. Elegir entre sensibilidad y especificidad no es un cálculo puramente matemático, sino un balance de costos asimétricos y responsabilidad ética, donde la configuración del modelo refleja qué tipo de error (falso positivo o falso negativo) resulta más aceptable en el dominio de aplicación.

8. Rúbrica de Evaluación

Esta es la rúbrica simplificada, lista para ser cargada en Moodle:

Criterio	Puntaje	Descripción
Implementación Técnica	3.0 pts	Ejecución correcta del modelo (simulado y regional) y limpieza/documentación del código.
Análisis y Diagnóstico	5.0 pts	Interpretación de coeficientes, diagnóstico efectivo de multicolinealidad (VIF) y visualización.
Reflexión Crítica	2.0 pts	Calidad y profundidad en las respuestas a las preguntas de control (enfoque aristotélico).
Total	10.0 pts	



unl

Universidad
Nacional
de Loja

9. Bibliografía

Liste las fuentes utilizadas. Use normas IEEE. Pueden ser libros, manuales, artículos, tutoriales académicos, documentación oficial de software.

- [1] R. E. Walpole, R. H. Myers, S. L. Myers, y K. Ye, *Probabilidad y estadística para ingeniería y ciencias*, 9na ed. Pearson Educación, 2012.
- [2] W. McKinney, *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*, 3ra ed. O'Reilly Media, 2022.
- [3] SciPy Developers, "scipy.stats Documentation," *SciPy.org*, 2024. [Online]. Disponible: <https://docs.scipy.org/doc/scipy/reference/stats.html>. [Accedido: 18-Mar-2026].



unl

Universidad
Nacional
de Loja

10. Elaboración y Aprobación

- Elaborado por: nombre del Docente responsable de la práctica.
- Aprobado por: nombre del Director de Carrera.

Elaborado por	Cristian R. Narváez Guillén Docente	
Aprobado por	Edison L Coronel Romero Director de Carrera	