



Guía de Actividades **Práctico-Experimentales** Nro. 015

Datos Generales

Estudiantes:	Kiara Condoy, Héctor Guerrero, Javier Guarnizo, Ricardo Ochoa, Emily Salas
Asignatura	Teoría de la Distribución y Probabilidad
Ciclo	2do "A"
Unidad	3
Resultado de aprendizaje de la unidad	Comprende los conceptos de variable aleatoria multidimensional y distribución de probabilidad asociada, bajo los principios de solidaridad, transparencia, responsabilidad y honestidad.
Práctica Nro.	015
Título de la Práctica	Evaluación Avanzada de Modelos: Curva ROC, Métrica AUC y Validación Cruzada (K-Fold)
Nombre del Docente	Cristian Ramiro Narváez Guillén
Fecha	Martes 27 de julio del 2026
Horario	11h30 – 13h30
Lugar	EVA Aula
Tiempo planificado en el Sílabo	2 horas

1. Objetivo(s) de la Práctica:

- **Cuantificar** el rendimiento global de un clasificador binario a través de múltiples umbrales de decisión trazando la Curva de Característica Operativa del Receptor (ROC) y calculando el Área Bajo la Curva (AUC) con scikit-learn.
- **Consolidar** y evaluar de forma definitiva el modelo probabilístico regional del Proyecto Integrador, preparando los artefactos técnicos y visuales para su exposición final (ABP).

- **Investigar** y ejecutar algoritmos de Validación Cruzada (K-Fold) para mitigar el sesgo estadístico introducido por particiones únicas de datos (Train/Test Split), previniendo el sobreajuste (ABI).

2. Materiales y reactivos:

- Entorno de desarrollo interactivo (Jupyter Notebook, Google Colab o Anaconda).
- Librerías de Python preinstaladas: numpy, pandas, scipy.stats, matplotlib, seaborn.
- Dataset regional del Proyecto Integrador limpio y validado.
- Conexión a Internet estable y continua.
- Navegador web actualizado.x|

3. Equipos y herramientas

- Recursos físicos: Aula de Computación.
- Computadora personal o portátil (PC o Laptop):
- Sistema operativo: Windows, Linux o macOS.
- Procesador: mínimo 2 núcleos (recomendado 4).
- Memoria RAM: mínimo 4 GB (recomendado 8 GB para manipulación de datasets con pandas).

4. Procedimiento / Metodología

Enfoque PID-2025:

- **ABP (Aprendizaje Basado en Problemas):** El estudiante descubrirá que predecir el comportamiento de su región usando una sola variable (Semana 13) es impreciso. Deberá combinar múltiples factores (ej. temperatura, humedad y altitud para predecir rendimiento agrícola) y decidir si vale la pena la complejidad adicional del modelo.
- **ABI (Aprendizaje Basado en Investigación):** Indagación sobre el "castigo matemático" que aplica el R^2 Ajustado cuando se añaden variables "basura" al modelo, y cómo descubrir si dos predictores están compitiendo entre sí (Multicolinealidad).
- **Duración sugerida:** 120 min. (presencial).
- **Modalidad:** Ejecución técnica individual con consolidación del modelo final para el Proyecto Integrador en grupos.

Enfoque PID-2025:

- **ABP (Aprendizaje Basado en Problemas):** El estudiante resolverá el desafío de empaquetar todo su análisis de ciclo en un producto coherente. Deberá demostrar que su modelo de predicción regional funciona consistentemente y no fue fruto de la casualidad estadística.
- **ABI (Aprendizaje Basado en Investigación):** Indagación matemática sobre el comportamiento estocástico de las métricas de rendimiento. Aprenderán que "un solo Accuracy del 90%" es estadísticamente dudoso sin un intervalo de confianza provisto por la validación cruzada.
- **Duración sugerida:** 120 min. (presencial).
- **Modalidad:** Ejecución técnica individual, con integración final en los grupos del Proyecto Integrador.

Tarea 1: La Curva ROC y el Área Bajo la Curva (AUC)

La Exactitud (*Accuracy*) vista en la Semana 15 depende de un umbral estático (ej. 0.5). La Curva ROC evalúa el modelo en **todos los umbrales posibles**, graficando la Tasa de Verdaderos Positivos (TPR o Sensibilidad) contra la Tasa de Falsos Positivos (FPR o $1 - \text{Especificidad}$):

$$TPR = \frac{TP}{TP + FN} \quad ; \quad FPR = \frac{FP}{FP + TN}$$

1. Abra un nuevo Jupyter Notebook llamado APE_016_ValidacionROC.ipynb.
2. Recuperando el modelo logístico (falla de servidores) de la Semana 15, genere el siguiente código para trazar la curva ROC:

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.metrics import roc_curve, auc, classification_report
from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import train_test_split

# 1. Simulación rápida de los datos de la Semana 15
np.random.seed(42)
temp_cpu = np.random.uniform(40, 90, 500).reshape(-1, 1) # X
z = -10 + 0.15 * temp_cpu.ravel()
```



```
prob_falla = 1 / (1 + np.exp(-z))
y_real = np.random.binomial(1, p=prob_falla) # Etiquetas (0 o 1)

# División en Entrenamiento y Prueba (70% - 30%)
X_train, X_test, y_train, y_test = train_test_split(temp_cpu, y_real,
test_size=0.30, random_state=42)

# 2. Entrenamiento del Modelo (Usando scikit-learn por compatibilidad con
métricas ROC)
modelo = LogisticRegression()
modelo.fit(X_train, y_train)

# Obtener las PROBABILIDADES estimadas para el conjunto de prueba, no
solo las clases (0/1)
# predict_proba devuelve [Prob_Clase_0, Prob_Clase_1]. Tomamos la
columna 1.
y_prob_test = modelo.predict_proba(X_test)[:, 1]

# 3. Cálculo de la Curva ROC y AUC
fpr, tpr, umbrales = roc_curve(y_test, y_prob_test)
roc_auc = auc(fpr, tpr)

# 4. Visualización
plt.figure(figsize=(8, 6))
plt.plot(fpr, tpr, color='darkorange', lw=2, label=f'Curva ROC (AUC =
{roc_auc:.3f})')
plt.plot([0, 1], [0, 1], color='navy', lw=2, linestyle='--', label='Clasificador Aleatorio
(AUC = 0.5)')
plt.xlim([0.0, 1.0])
plt.ylim([0.0, 1.05])
plt.xlabel('Tasa de Falsos Positivos (FPR)')
plt.ylabel('Tasa de Verdaderos Positivos (TPR)')
plt.title('Curva Característica Operativa del Receptor (ROC)')
plt.legend(loc="lower right")
plt.grid(alpha=0.3)
plt.show()
```



unl

Universidad
Nacional
de Loja

FEIRNNR - Carrera de
Computación

```
# Reporte detallado de clasificación con umbral por defecto (0.5)
```

```
y_pred_test = modelo.predict(X_test)
```

```
print("\n--- Reporte de Clasificación (Threshold = 0.5) ---")
```

```
print(classification_report(y_test, y_pred_test))
```

Tarea 2: Hito Final del Proyecto - Consolidación del Modelo Regional (ABP)

Esta tarea requiere la integración de su equipo de trabajo.

1. Abran el archivo Jupyter principal de su Proyecto Integrador.
2. Identifiquen el mejor modelo predictivo generado durante el ciclo (Regresión Lineal Múltiple de la Sem 14 o Regresión Logística de la Sem 15).
3. **Si es Clasificación (Logística):** Replique el código de la Tarea 1 para graficar la Curva ROC de su proyecto y reporte el valor AUC.
4. **Si es Regresión (Lineal):** Calcule las métricas RMSE (Root Mean Squared Error) y MAE (Mean Absolute Error) comparando `y_test` con `y_pred_test`.
5. Redacten un párrafo ejecutivo (formato Markdown) que sintetice la utilidad del modelo: *¿Es este modelo lo suficientemente preciso como para ser implementado en una empresa o institución de Loja?*

Tarea 3: Preparación de Visualizaciones para la Casa Abierta

Para la presentación de la Semana 17, el código crudo no es suficiente; se requiere comunicación efectiva.

1. Construya al menos **dos gráficos de alto impacto visual** utilizando seaborn que resuman el problema regional y la solución predictiva.
2. Limpie su Notebook: elimine celdas de pruebas fallidas, estructure con títulos #, ##, y asegúrese de que el flujo de lectura (Data Cleaning → EDA → Modeling → Evaluation) sea lógico y profesional.

Tarea 4: ABI - Validación Cruzada Estocástica (K-Fold Cross Validation)

El `train_test_split` es peligroso: dependiendo de la semilla aleatoria (`random_state`), el modelo puede parecer excelente o terrible por pura suerte probabilística.

1. Investigue el concepto de K -Fold Cross Validation.
2. Ejecute el siguiente código para dividir su set de entrenamiento simulado en 5 "dobles" (Folds) y calcular el rendimiento promedio.

```
from sklearn.model_selection import cross_val_score

# Ejecutar validación cruzada con K=5 folds
k_folds = 5
# cv requiere el modelo, los predictores (X) y las respuestas (y). Usamos el set completo.
scores_auc = cross_val_score(modelo, temp_cpu, y_real, cv=k_folds,
                              scoring='roc_auc')

print(f'--- Análisis de Validación Cruzada (K={k_folds}) ---')
print(f'AUC de cada Fold: {np.round(scores_auc, 3)}')
print(f'AUC Promedio Estocástico (E[AUC]): {scores_auc.mean():.3f}')
print(f'Desviación Estándar ( $\sigma_{AUC}$ ):  $\pm$ {scores_auc.std():.3f}')

if scores_auc.std() > 0.10:
    print("Advertencia: El modelo es inestable (alta varianza entre particiones).")
else:
    print("Éxito: El modelo es estable y generaliza bien.")
```

3. Aplique `cross_val_score` a su modelo regional del Proyecto Integrador. Documente si la desviación estándar del rendimiento le da confianza matemática para implementarlo en producción.

5. Resultados esperados:

Al finalizar esta práctica, el estudiante habrá logrado:

- Generar y visualizar correctamente la curva ROC, calculando el Área Bajo la Curva (AUC) para clasificadores binarios.
- Consolidar el modelo predictivo del Proyecto Integrador, reportando métricas de rendimiento validadas (AUC/RMSE/MAE).
- Ejecutar la Validación Cruzada (K-Fold) para evaluar la estabilidad estocástica del modelo, obteniendo su media y desviación estándar.
- Crear dos visualizaciones de impacto para la comunicación efectiva de resultados en la Casa Abierta.

6. Preguntas de Control:

1. ¿Cuál es la naturaleza de un clasificador cuyo AUC es 0.5 y por qué su comportamiento es ontológicamente indistinguible del azar?

Un clasificador con un **Área Bajo la Curva (AUC) de 0.5** representa un modelo sin ninguna capacidad de discriminación o poder predictivo.

Su comportamiento es **ontológicamente indistinguible del azar** porque la relación entre la Tasa de Verdaderos Positivos (**TPR**) y la Tasa de Falsos Positivos (**FPR**) equivale a la línea diagonal de referencia (**$y = x$**). Esto implica que la probabilidad de que el modelo asigne una puntuación más alta a una instancia positiva sobre una negativa es del 50%. En términos probabilísticos y ontológicos, el "juicio" del modelo no contiene conocimiento intrínseco sobre el fenómeno, operando exactamente igual que el lanzamiento de una moneda no cargada.

2. ¿Es posible afirmar que un modelo es "bueno" basándonos exclusivamente en la exactitud (Accuracy), ignorando la calidad de su juicio sobre las clases minoritarias?

No, no es posible. La exactitud (*Accuracy*) mide el porcentaje general de predicciones correctas sobre el total. Sin embargo, esta métrica es severamente engañosa en conjuntos de datos desbalanceados.

Por ejemplo, si un problema de clasificación de deforestación crítica representa solo el **5%** de los datos, un modelo ingenuo que clasifique el **100%** de los casos como "sin deforestación" obtendrá una *Accuracy* del **95%**. A pesar del alto porcentaje, el modelo es completamente inútil para la toma de decisiones porque su sensibilidad (*Recall*) o capacidad de detectar la clase de interés (clase minoritaria) es nula. Para determinar la calidad real de un modelo se requiere evaluar métricas complementarias como *Precision*, *Recall*, *F1-score* y la curva ROC/AUC.

3. Si un modelo fluctúa drásticamente su rendimiento al cambiar los subconjuntos de datos (*folds*), ¿podemos decir que posee un "conocimiento" robusto o simplemente ha memorizado patrones accidentales?

Si las métricas del modelo (como el R^2 o el RMSE) cambian drásticamente entre cada *fold* en una Validación Cruzada, el modelo **no posee un conocimiento robusto**, sino que ha incurrido en **sobreajuste (overfitting)**.

Esta alta varianza revela que el algoritmo ha "memorizado" el ruido, el sesgo estadístico o los patrones accidentales propios de un subconjunto específico de datos de entrenamiento en lugar de aprender las relaciones subyacentes del fenómeno. Un modelo con verdadero poder de generalización debe mantener un rendimiento estable y consistente frente a múltiples particiones o realidades no vistas.

4. Al someter al modelo a múltiples realidades mediante la Validación Cruzada, ¿cómo nos acercamos más a la esencia de su capacidad predictiva en comparación con una prueba única?

Una división única (*Train/Test Split*) evalúa al modelo frente a una "sola realidad", donde los resultados de rendimiento pueden verse inflados u opacados por un sesgo de partición aleatoria de datos (*random state*).

La **Validación Cruzada** (*K-Fold*) somete al algoritmo a **K** particiones distintas, entrenando y evaluando el modelo en múltiples escenarios. Al calcular la media estocástica y la desviación estándar del rendimiento a través de los **K folds**, nos acercamos a la verdadera capacidad predictiva y de generalización del modelo. Esto permite mitigar el sesgo estadístico y verificar si sus predicciones son estables independientemente de cómo se divida la muestra.

5. ¿Por qué el rigor estocástico y el escepticismo matemático constituyen una virtud necesaria para el ingeniero al momento de comunicar la verdad de sus modelos a la sociedad?

El rigor estocástico y el escepticismo matemático son virtudes esenciales porque **las decisiones basadas en modelos de datos tienen un impacto directo en el mundo real**.

En el contexto regional del proyecto (por ejemplo, el monitoreo de deforestación para la Prefectura de Loja o el MAATE), reportar métricas infladas o modelos no validados mediante *K-Fold* puede llevar a políticas públicas fallidas, mala asignación de recursos o la incapacidad de prevenir desastres ambientales. Un ingeniero debe dudar de los éxitos aparentes en muestras pequeñas, validar probabilísticamente las desviaciones y comunicar de manera honesta y transparente tanto el alcance como las limitaciones de sus herramientas predictivas.

7. Conclusiones.

- El modelo de Regresión Logística implementado en la Tarea 1 demostró un rendimiento sobresaliente en la clasificación de fallas/riesgo, alcanzando un valor de $AUC = 0.922$ y un *Accuracy* del 82%. Esto confirma la utilidad de la Curva ROC para evaluar el desempeño global del clasificador a través de distintos umbrales de decisión de forma independiente al balance de clases.
- En el análisis regional de pérdida de cobertura arbórea en Loja (2001–2024), el modelo de Regresión Lineal Múltiple no mostró una relación lineal fuerte frente al factor tiempo ($R^2 = -0.1421$ – *en conjunto de prueba* / R^2 OLS = 0.02) Esto evidencia que la deforestación obedece a dinámicas multivariadas y estocásticas (picos interanuales por factores climáticos o antrópicos) que requieren modelos no lineales o multivariados.



- La incorporación de métodos como *K-Fold Cross-Validation* resulta indispensable para obtener estimaciones no sesgadas de los errores (como RMSE y MAE). Probar los algoritmos en múltiples particiones previene que los ingenieros tomen decisiones de implementación basadas en métricas optimistas obtenidas por simple azar en un único *Train/Test Split*.

Declaración de uso de IA:

Por medio de la presente, declaro que he utilizado la herramienta de Inteligencia Artificial Gemini para asistirme en la redacción, estructuración y formato en Markdown de las preguntas de control y conclusiones correspondientes a la Guía de Actividades Práctico-Experimentales Nro. 015.

El contenido técnico, el análisis de los resultados del modelo y la validación de los conceptos expuestos han sido revisados y respaldados bajo la responsabilidad del estudiante.

Enlace a Google Colab:

<https://colab.research.google.com/drive/1WueoCvdoJJw5pxmyQtmv0D-KilsG7QHr?usp=sharing>

8. Rúbrica de Evaluación

Esta es la rúbrica simplificada, lista para ser cargada en Moodle:

Criterio	Puntaje	Descripción
Implementación Técnica	3.0 pts	Ejecución correcta del modelo (simulado y regional) y limpieza/documentación del código.
Análisis y Diagnóstico	5.0 pts	Interpretación de coeficientes, diagnóstico efectivo de multicolinealidad (VIF) y visualización.
Reflexión Crítica	2.0 pts	Calidad y profundidad en las respuestas a las preguntas de control (enfoque aristotélico).
Total	10.0 pts	



9. Bibliografía

Liste las fuentes utilizadas. Use normas **IEEE**. Pueden ser libros, manuales, artículos, tutoriales académicos, documentación oficial de software.

[1] R. E. Walpole, R. H. Myers, S. L. Myers, y K. Ye, *Probabilidad y estadística para ingeniería y ciencias*, 9na ed. Pearson Educación, 2012.

[2] W. McKinney, *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*, 3ra ed. O'Reilly Media, 2022.

[3] SciPy Developers, "scipy.stats Documentation," *SciPy.org*, 2024. [Online]. Disponible: <https://docs.scipy.org/doc/scipy/reference/stats.html>. [Accedido: 18-Mar-2026].



10. Elaboración y Aprobación

- Elaborado por: nombre del Docente responsable de la práctica.
- Aprobado por: nombre del Director de Carrera.

Elaborado por	Cristian R. Narváez Guillén Docente	
Aprobado por	Edison L Coronel Romero Director de Carrera	